

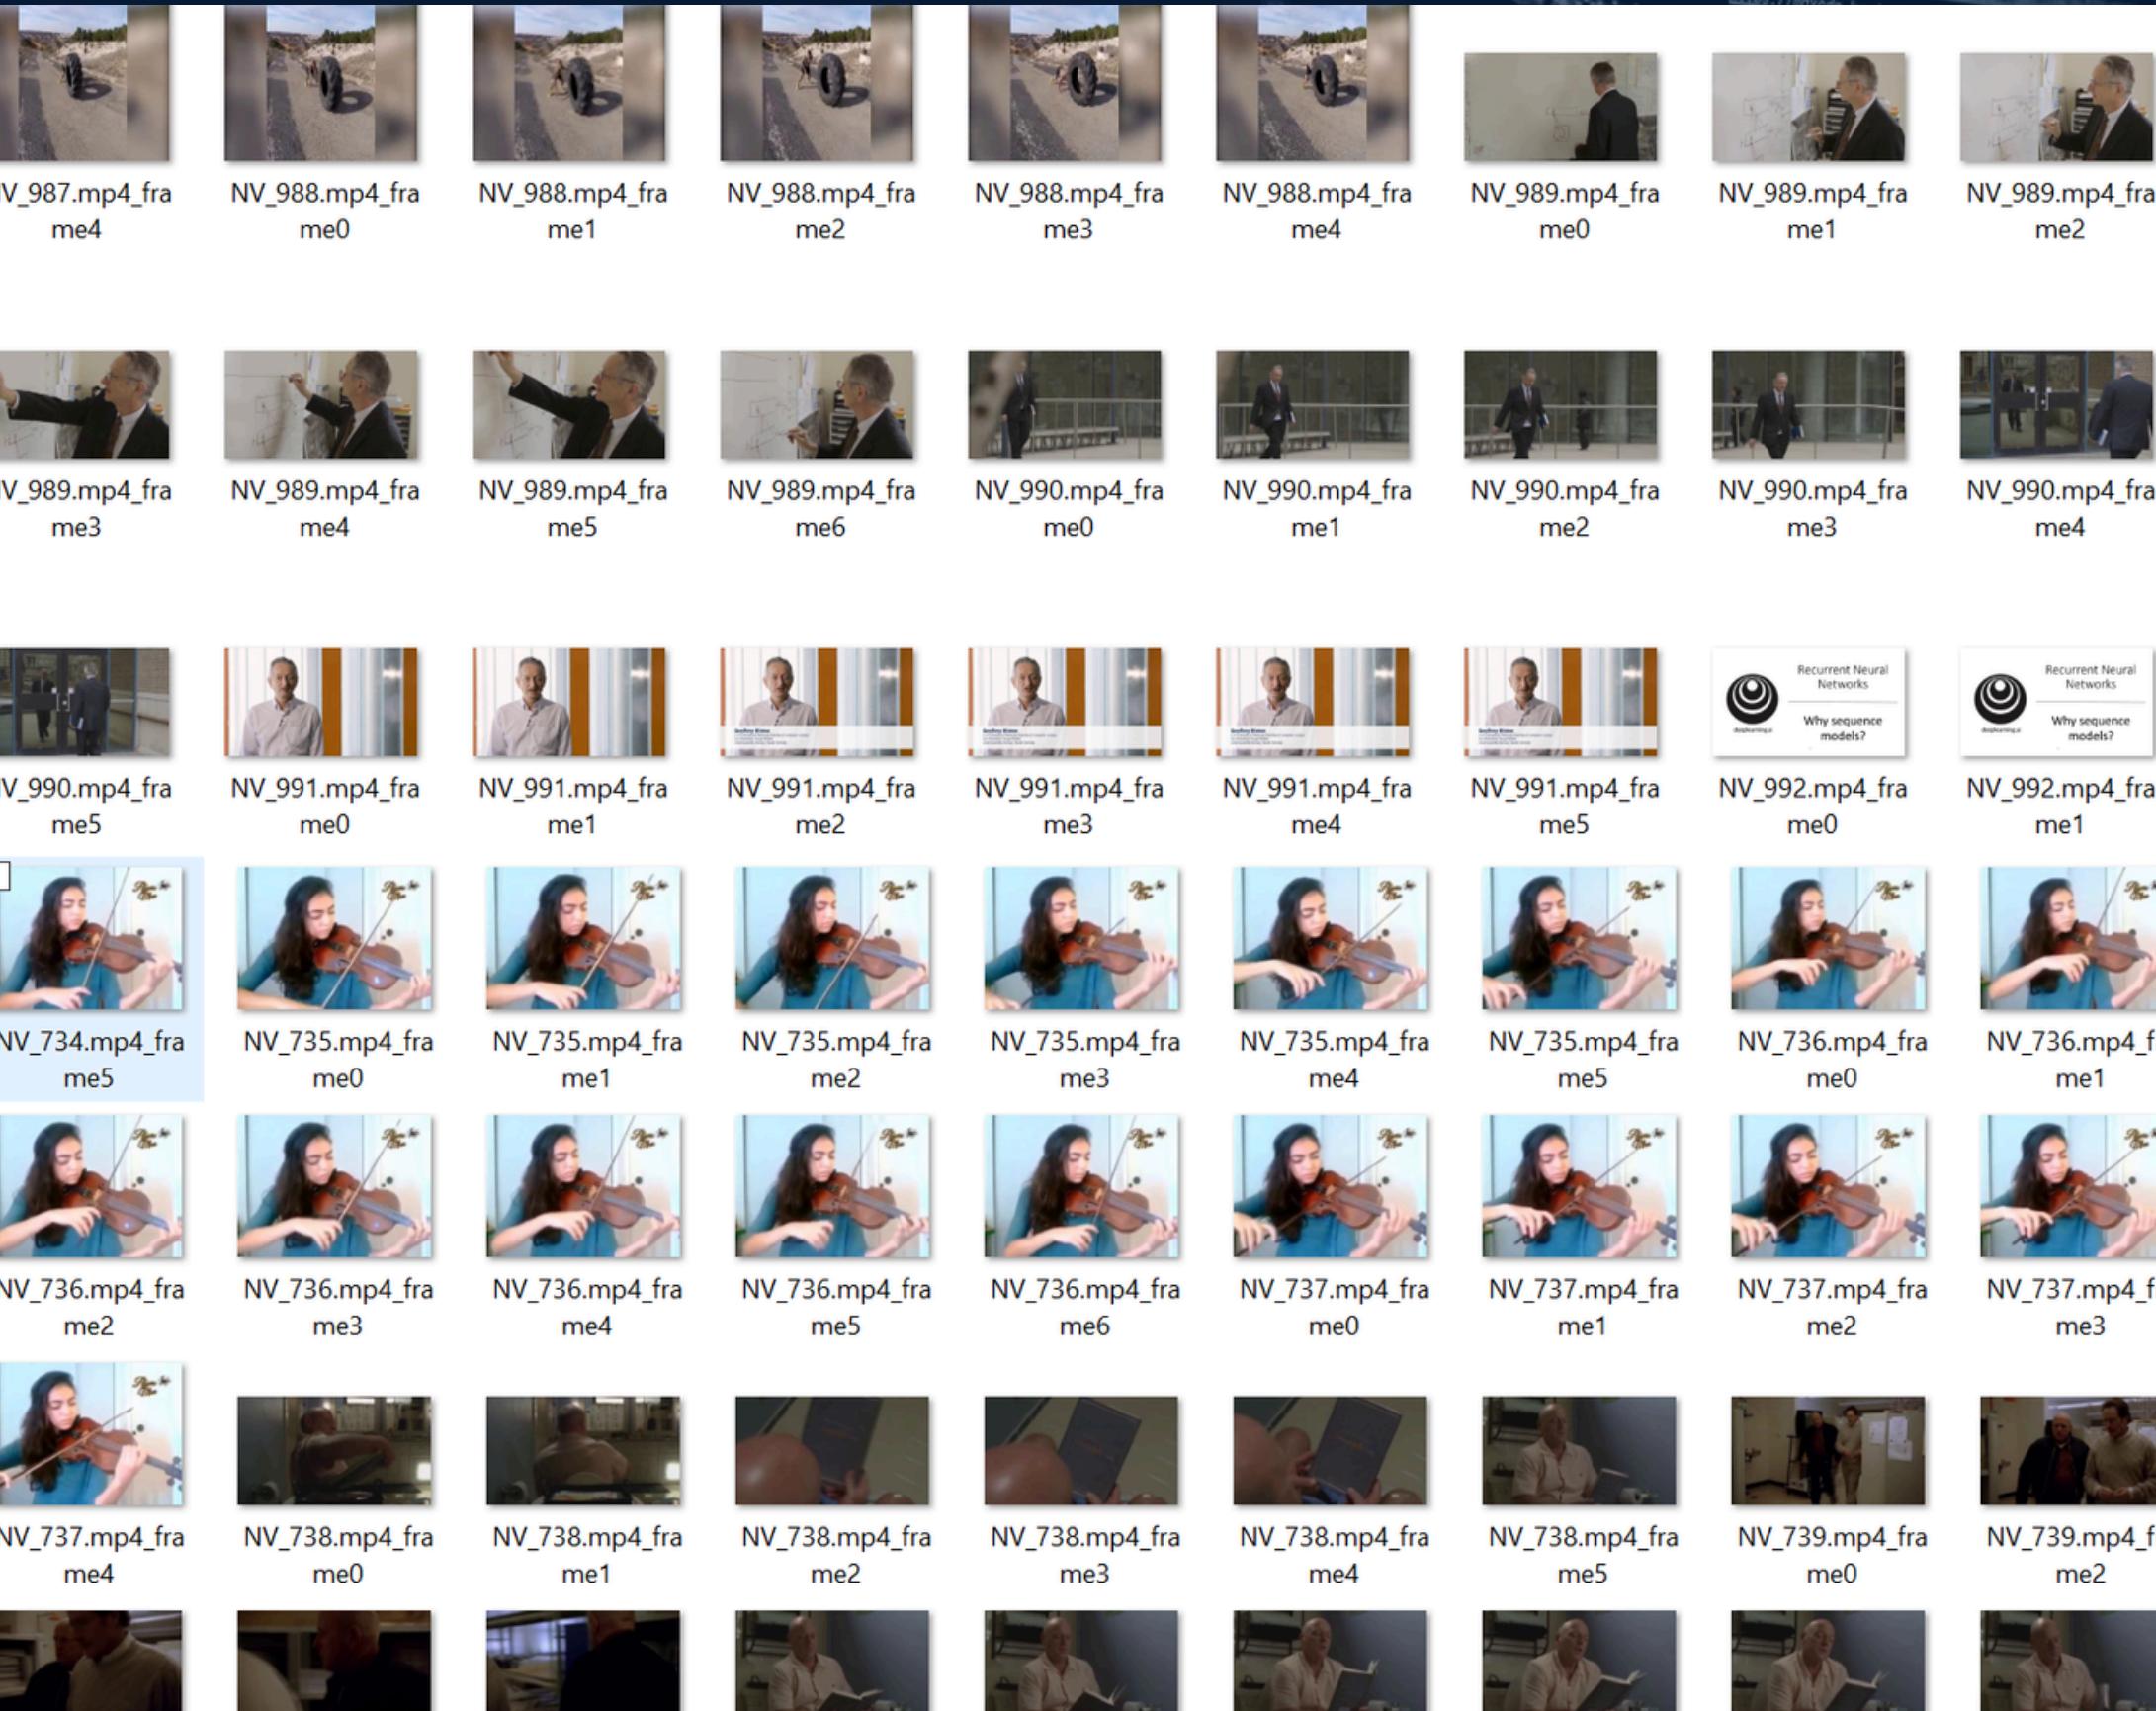
PROYECTO FINAL VISIÓN POR COMPUTADOR

DALIA CASTRO BUENO

1/ DESCRIPCIÓN DEL DATASET

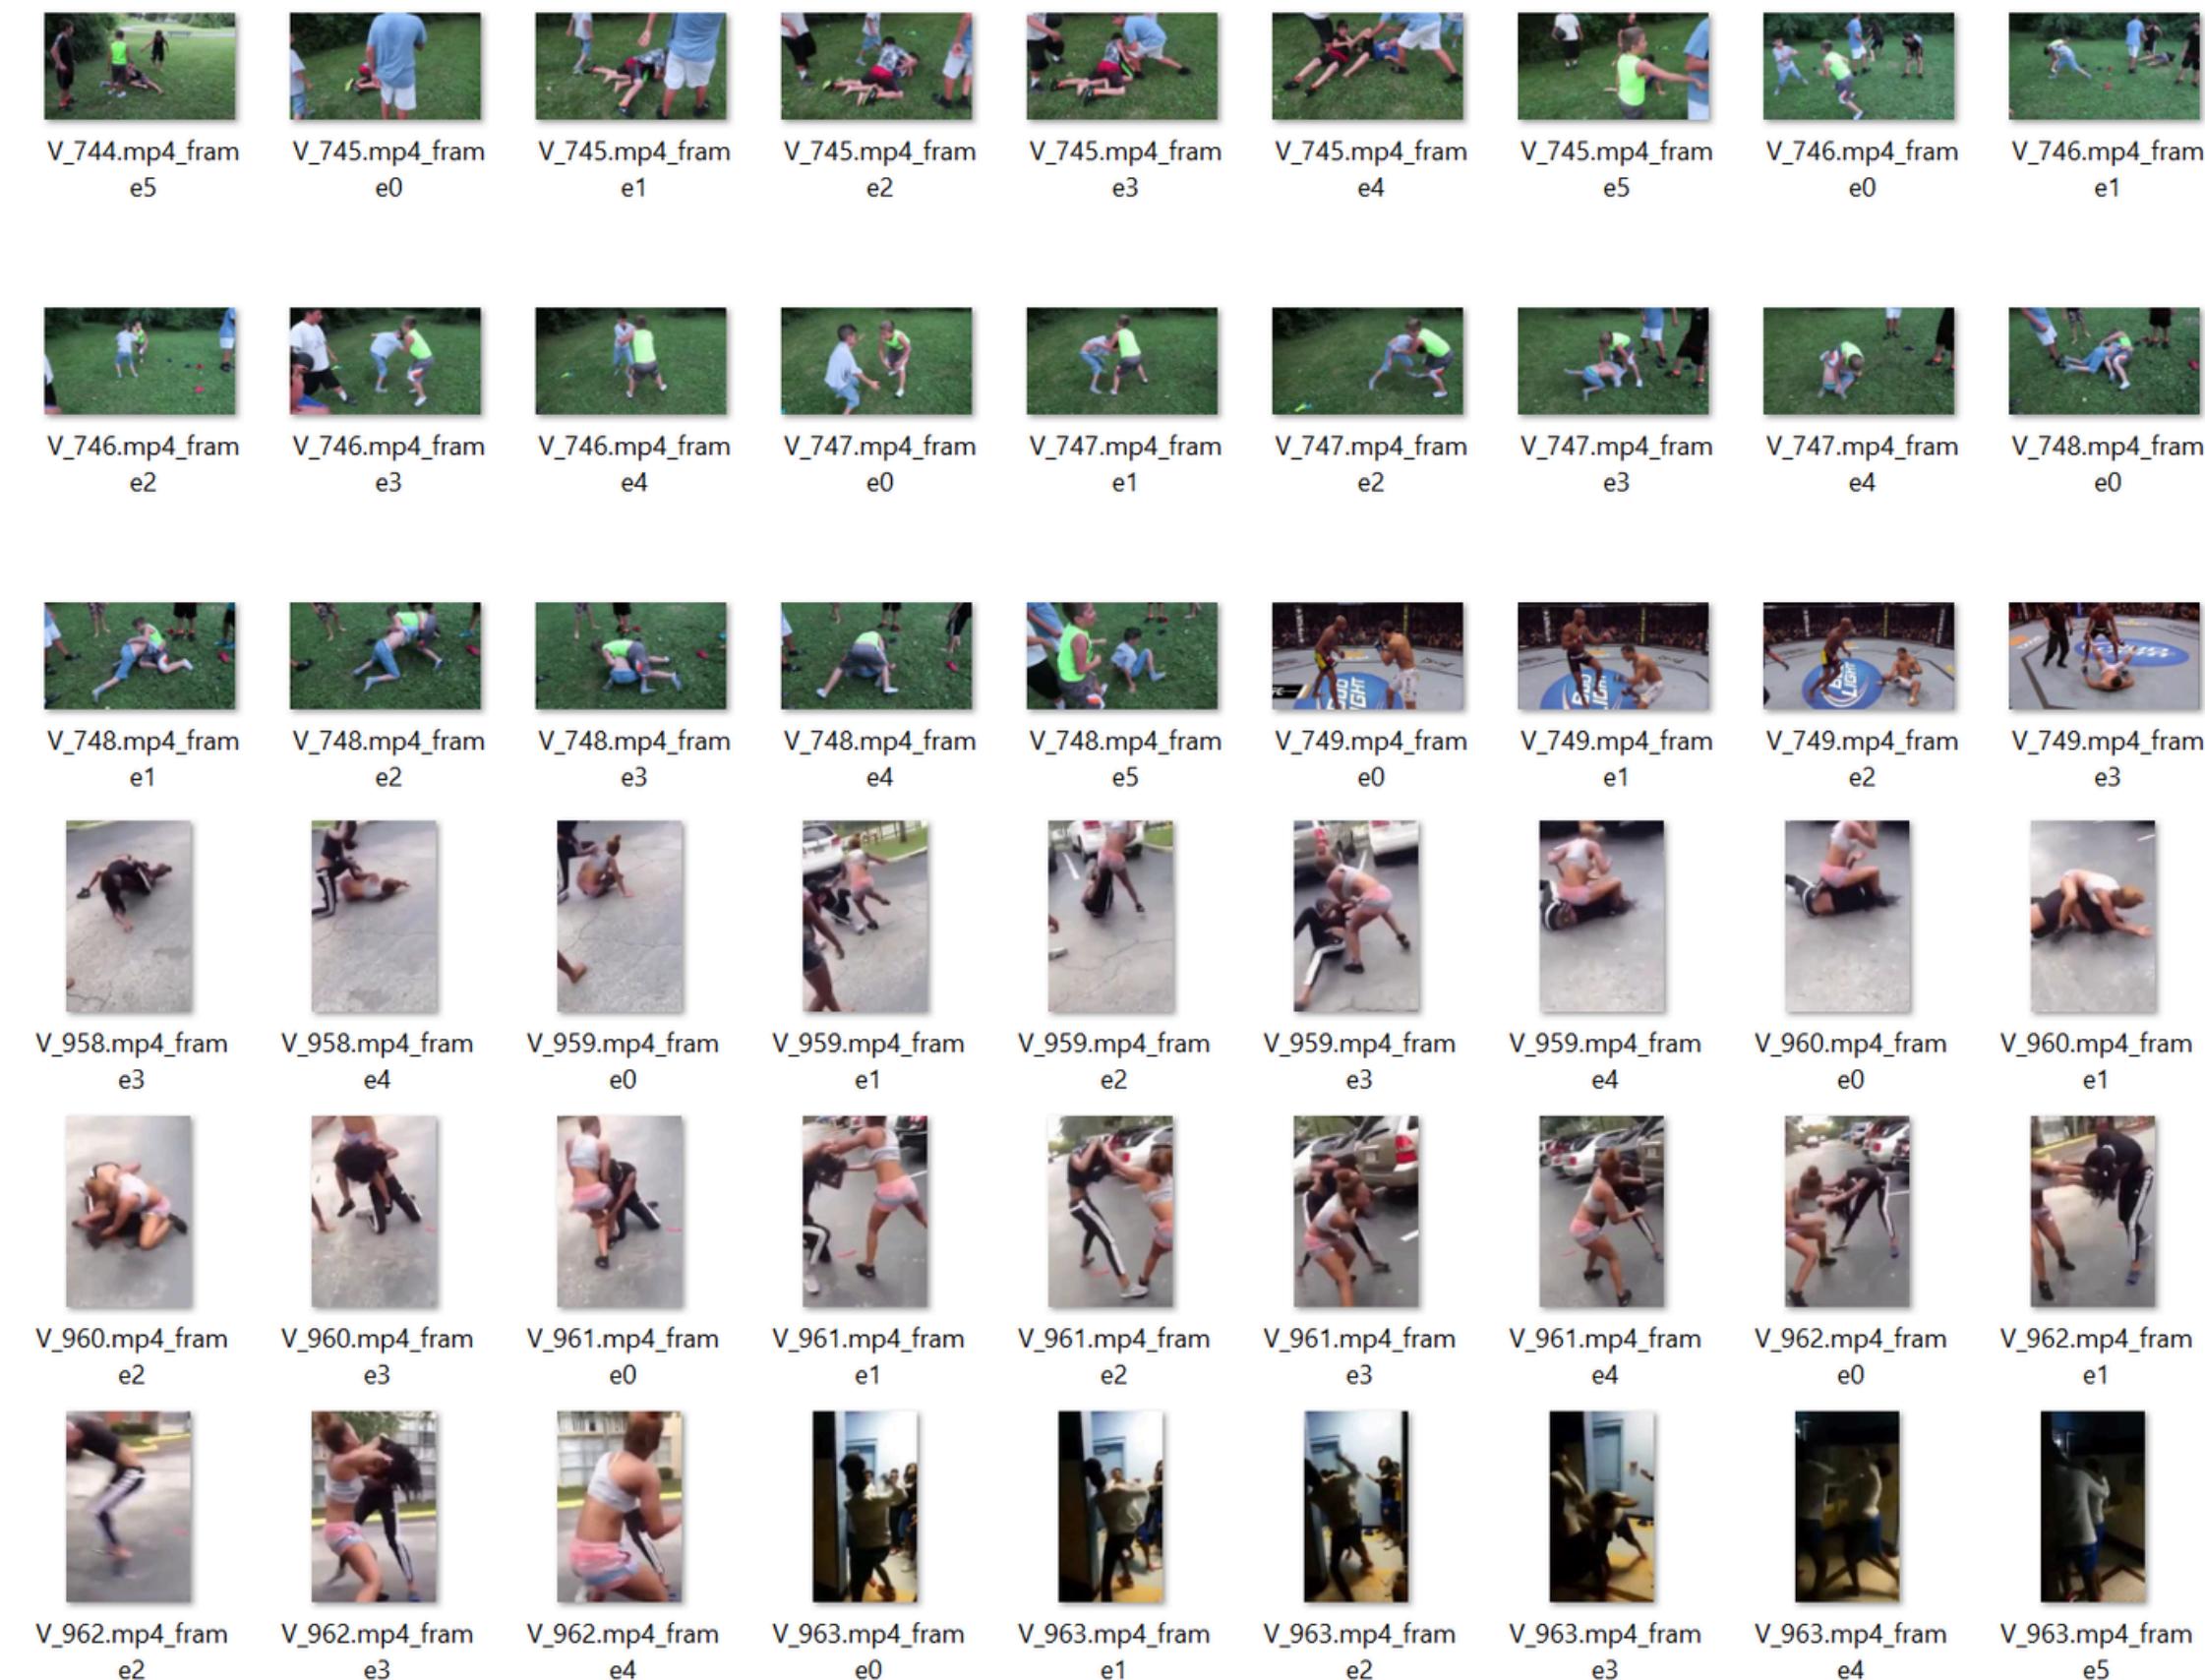
1/ DESCRIPCIÓN DEL DATASET

5231 imágenes



1/ DESCRIPCIÓN DEL DATASET

5832 imágenes

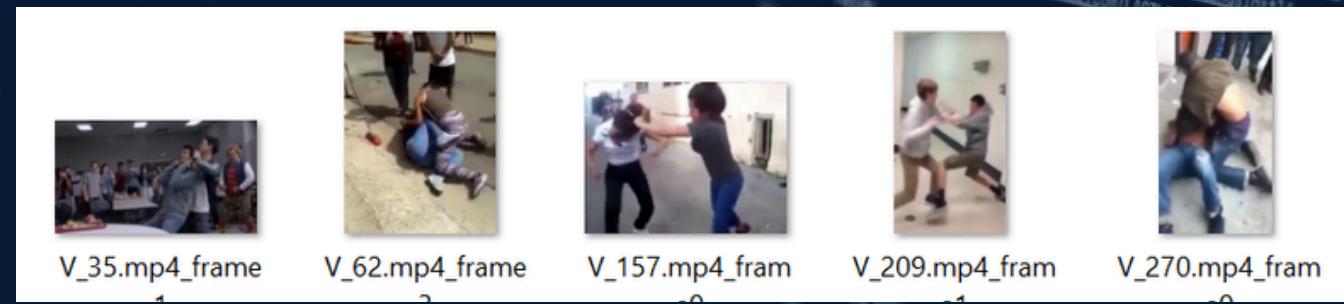
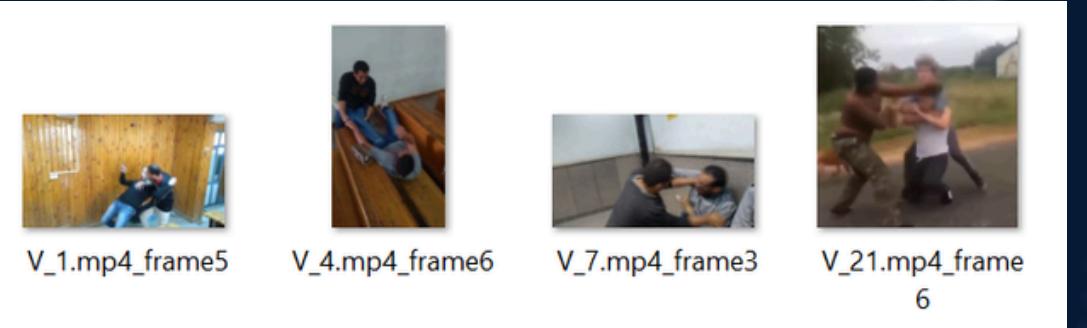


1/ DESCRIPCIÓN DEL DATASET

PRUEBA



15 imágenes



2 / METODOLOGÍA

2 / METODOLOGÍA



PRE-PROCESAMIENTO
IMAGENES

TRAINING - VALIDACIÓN
- TESTING

RED NEURONAL
CONVOLUCIONAL

ACCURACY

3 / TÉCNICAS DE PREPROCESAMIENTO UTILIZADAS



3 / TÉCNICAS DE PREPROCESAMIENTO UTILIZADAS

CAMBIO DE ESPACIOS DE COLOR Y CANALES

- RGB
- HLS - CANAL L
- XYZ

BINARIZACIÓN Y ADAPTIVE_MEAN_THRESH OLD

CLAHE

4 / RED NEURONAL CONVOLUCIONAL

4 / RED NEURONAL CONVOLUCIONAL

- CAPA DE ENTRADA

Define las imágenes de entrada con un tamaño de 128x128 píxeles y n canales.

- PRIMERA CAPA CONVOLUCIONAL

Aplica 16 filtros de 3x3 para detectar características simples como bordes. Usa $\text{ReLU}(x) = \max(0,x)$ como activación y regularización L2 para evitar el sobreajuste. Batch Normalization estabiliza el entrenamiento y MaxPooling, que reduce el tamaño de las imágenes y conserva las características más importantes.

- SEGUNDA CAPA CONVOLUCIONAL

Esta capa tiene 32 filtros de 3x3 para capturar patrones más complejos. ReLU, Batch Normalization y MaxPooling siguen presentes para mantener la estabilidad y reducir las dimensiones.

4 / RED NEURONAL CONVOLUCIONAL

- **TERCERA CAPA CONVOLUCIONAL**

Con 64 filtros, esta capa detecta características más detalladas de las imágenes. Al igual que las anteriores, incluye ReLU, Batch Normalization y MaxPooling.

- **CUARTA CAPA CONVOLUCIONAL**

Usa 128 filtros para captar características complejas, mientras que ReLU, Batch Normalization y MaxPooling ayudan a la eficiencia y reducción de dimensiones.

- **CAPA FLATTEN()**

Convierte los datos multidimensionales en un vector unidimensional, listo para pasarse a las capas densas.

4 / RED NEURONAL CONVOLUCIONAL

- **PRIMERA CAPA DENSA**

Con 512 neuronas, conecta las características extraídas y usa ReLU para activar. Incluye regularización L2 y Batch Normalization para evitar el sobreajuste.

- **SEGUNDA CAPA DENSA**

Tiene 256 neuronas, también con activación ReLU y normalización, para refinar las características aprendidas.

- **CAPA DE SALIDA**

La capa final tiene tantas neuronas como clases, usando softmax (convierte las salidas en probabilidades -todas suman 1-, y la clase con la mayor probabilidad será la predicción del modelo) para convertir las salidas en probabilidades.

5 / RESULTADOS

5 / RESULTADOS

IMAGINES CRUDAS

Espacio RGB
Tamaño 128*128

Accuracy_training:
0.9520

Accuracy_validation:
0.8864

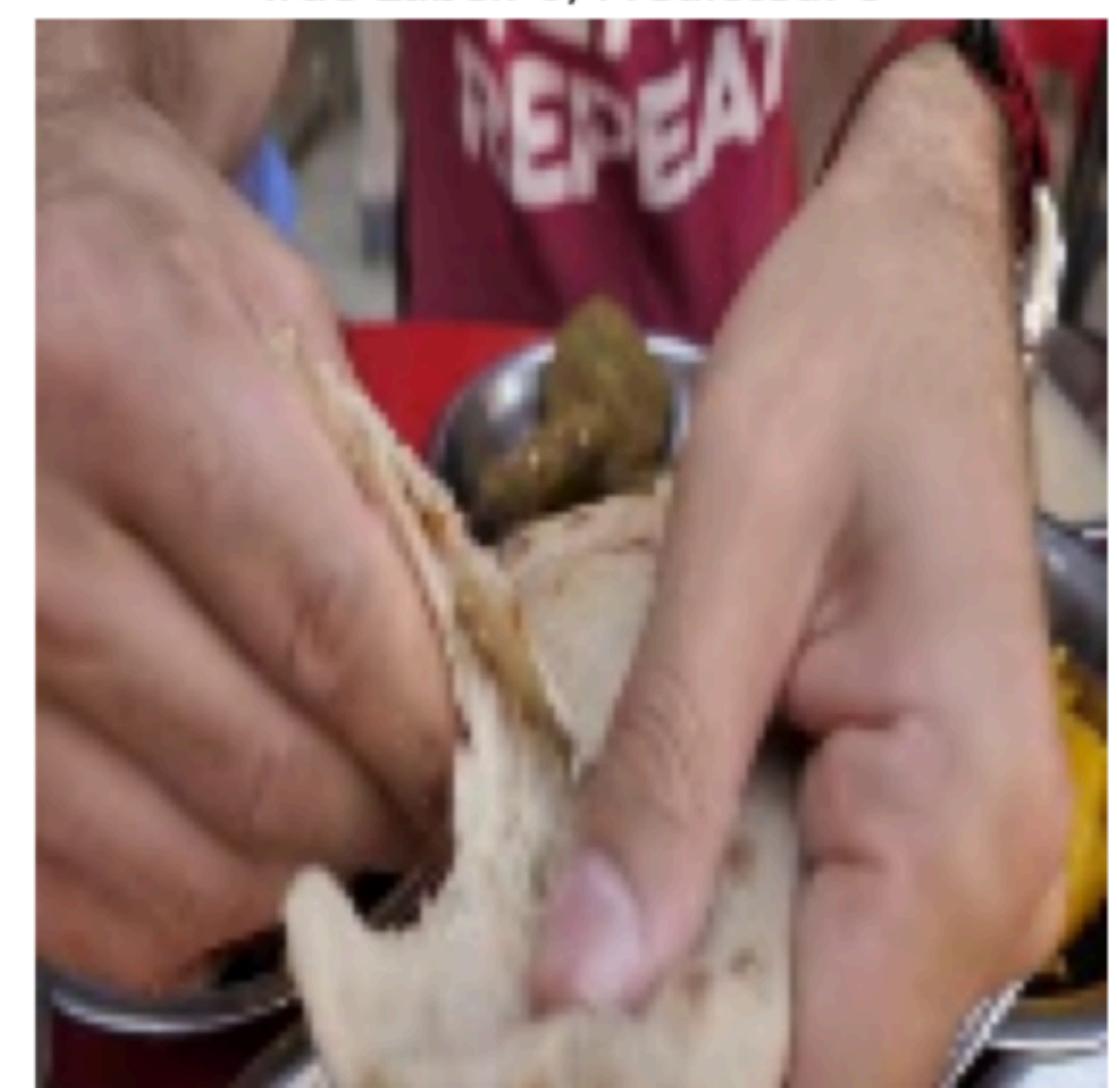




True Label: 0
Predicted Label: 0



True Label: 1
Predicted Label: 1



True Label: 0
Predicted Label: 0

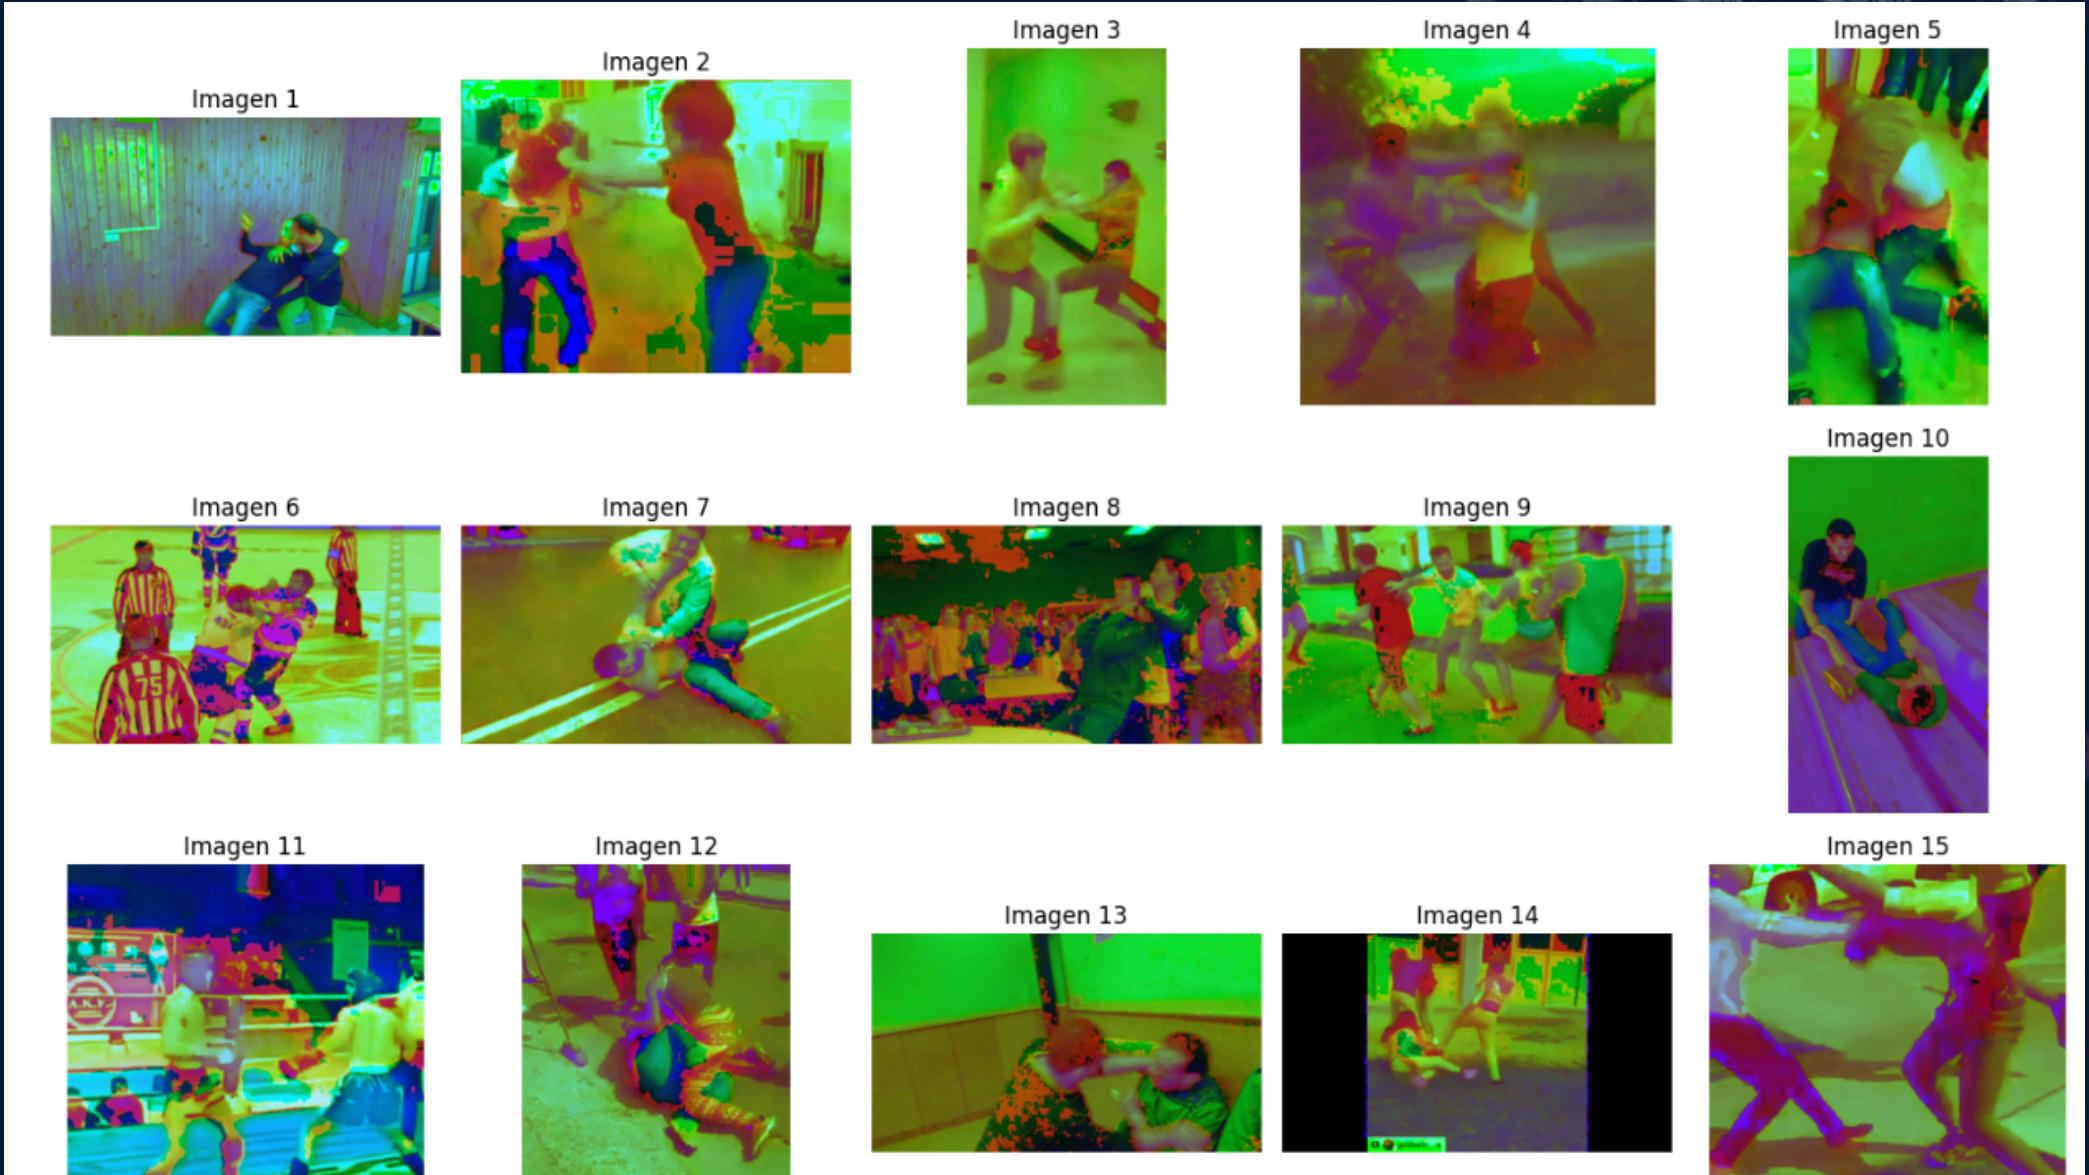
5 / RESULTADOS

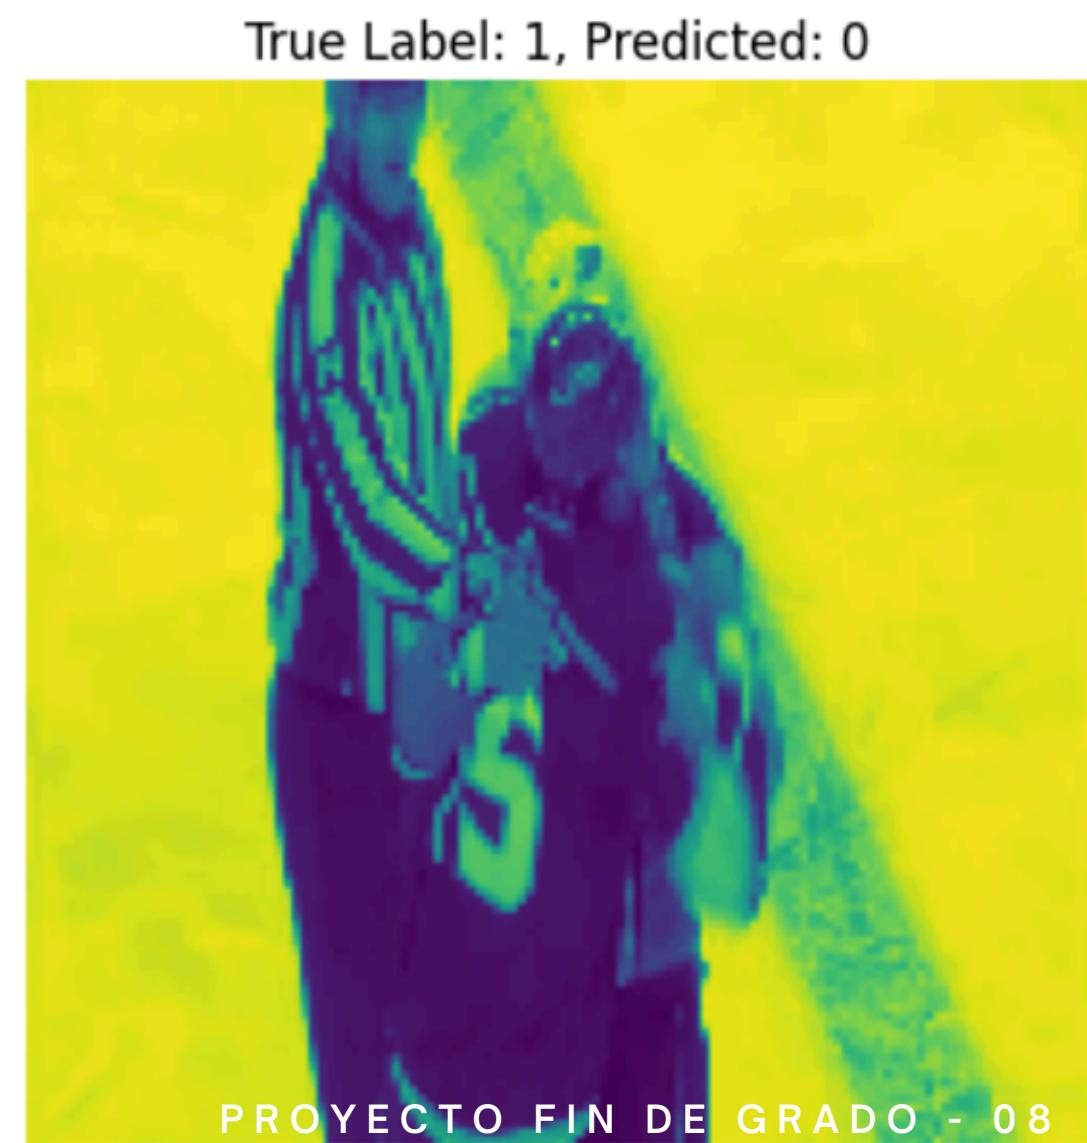
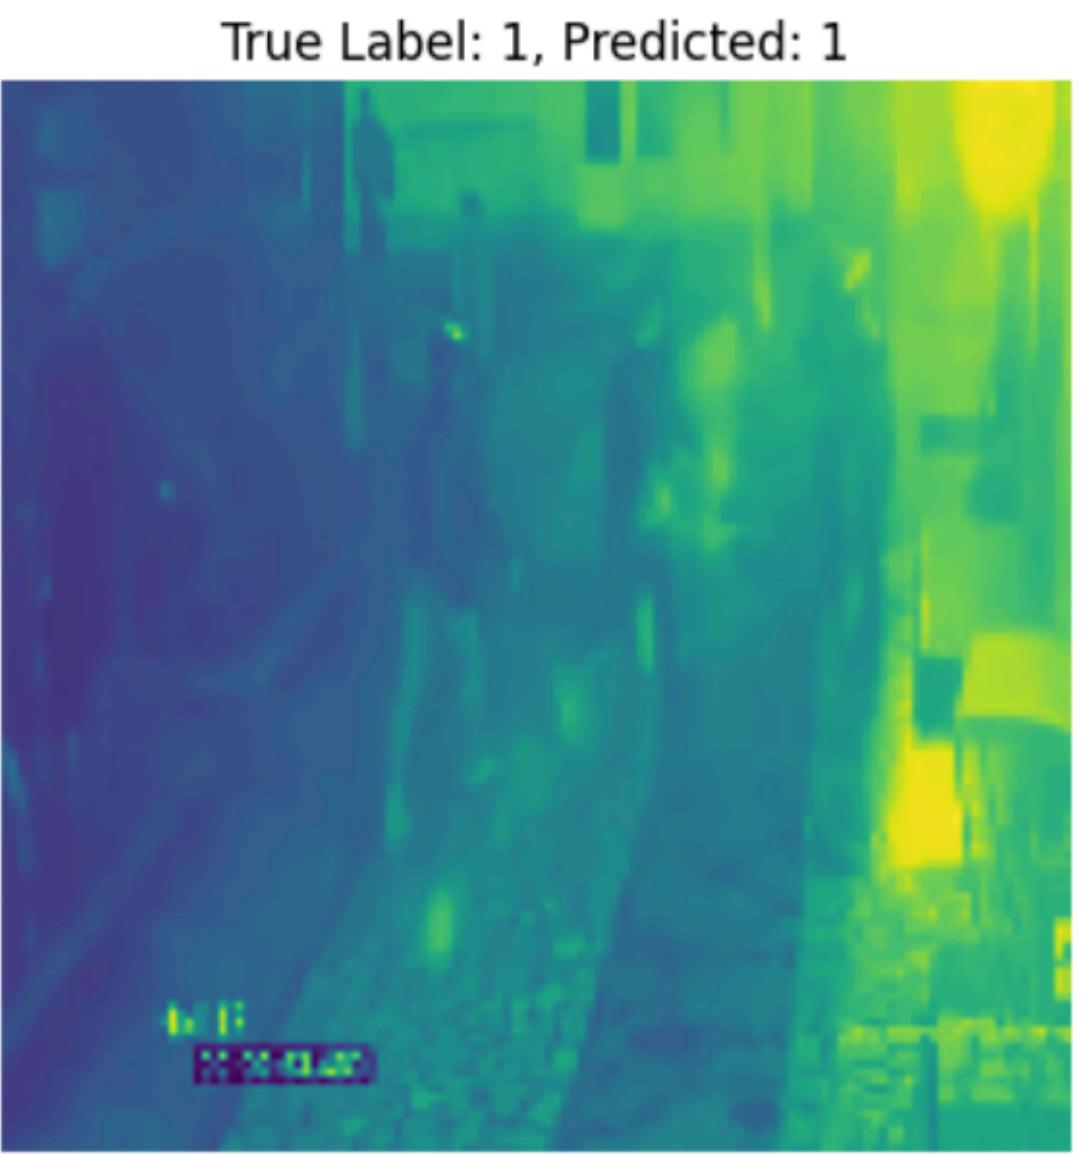
IMAGENES L

Espacio HLS - Canal L
Tamaño 128*128

Accuracy_training:
0.9408

Accuracy_validation: 0.8954





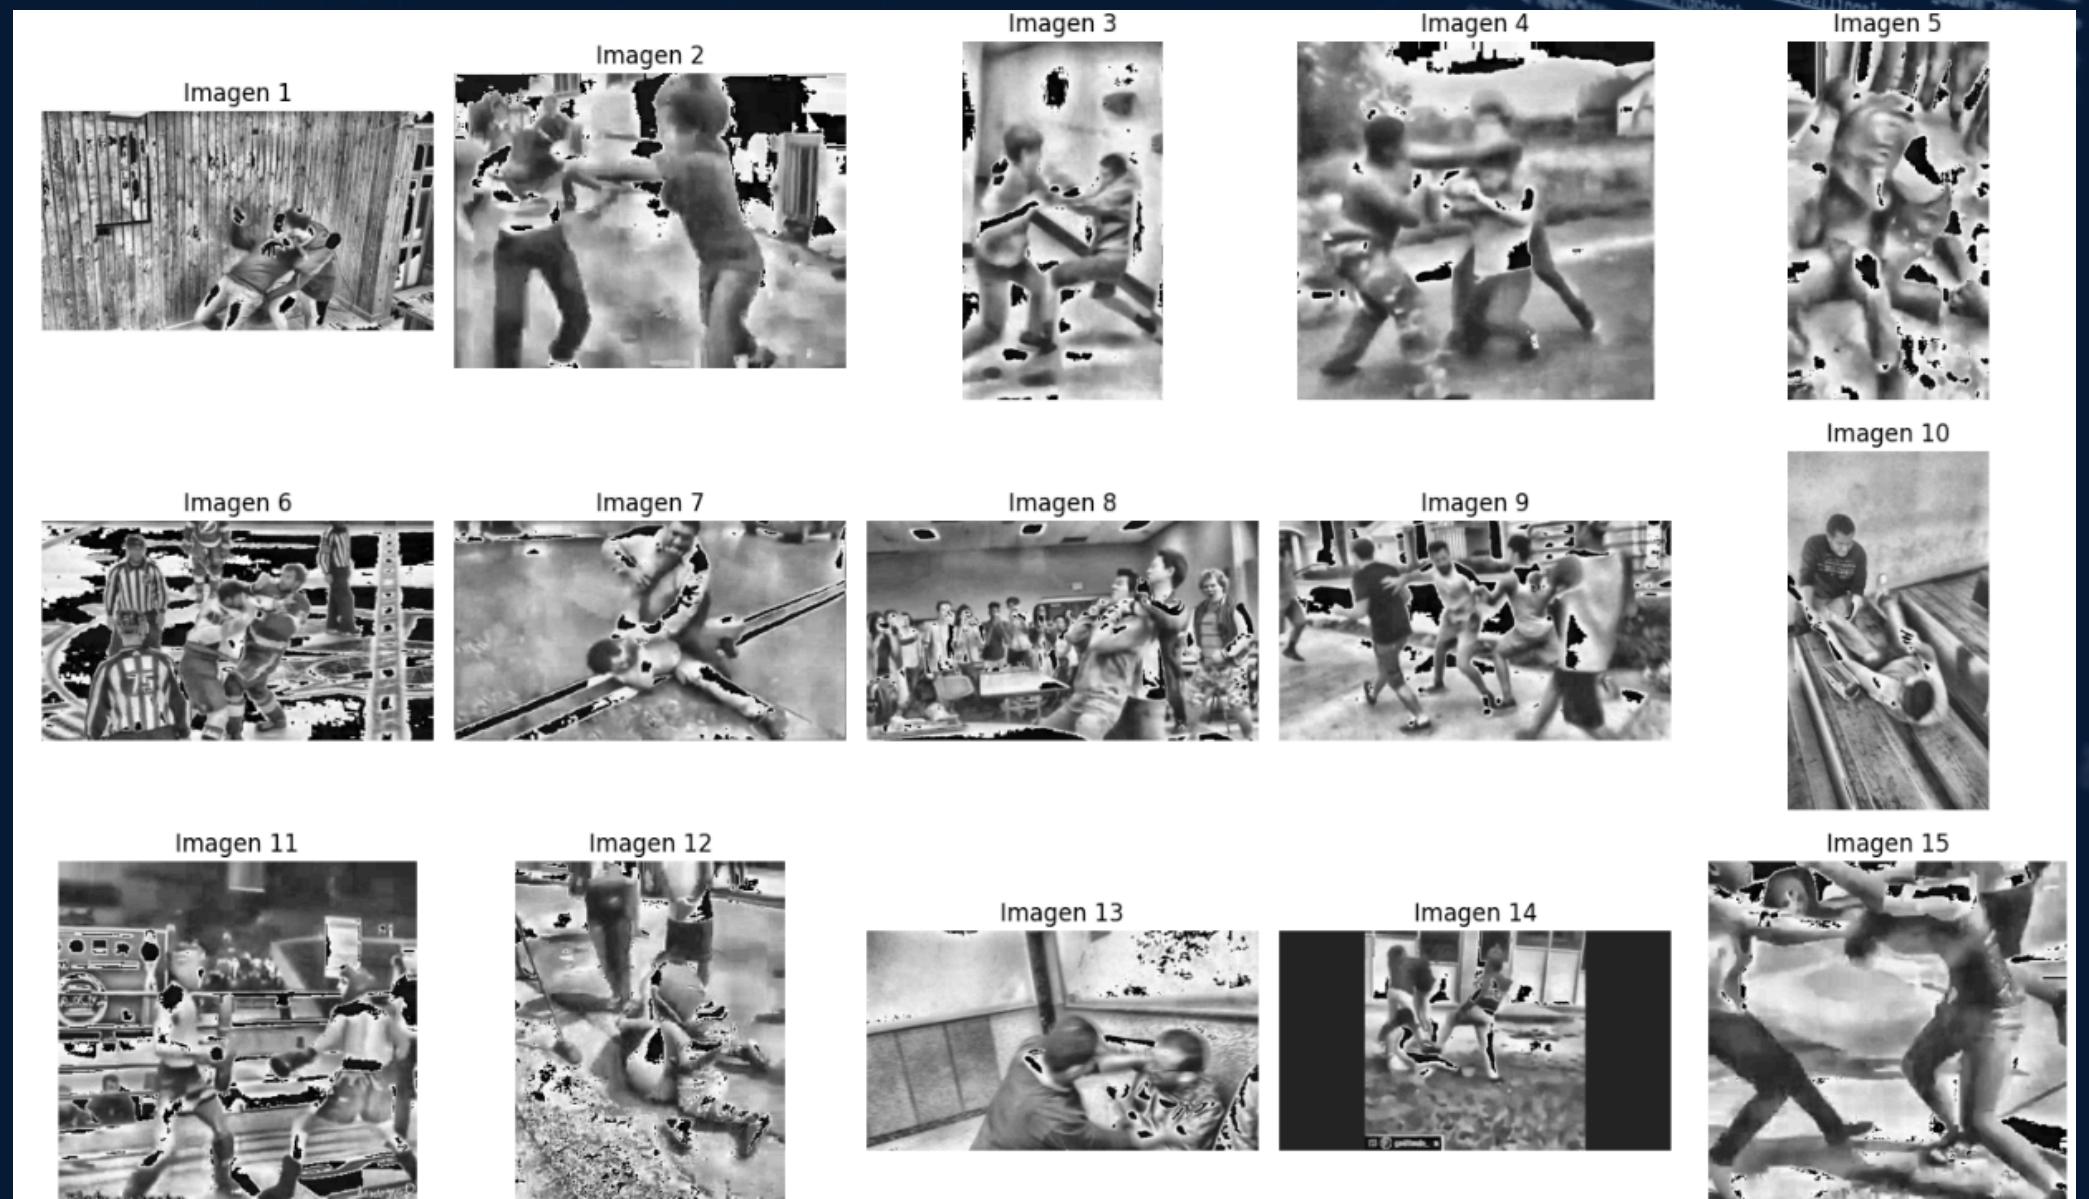
5 / RESULTADOS

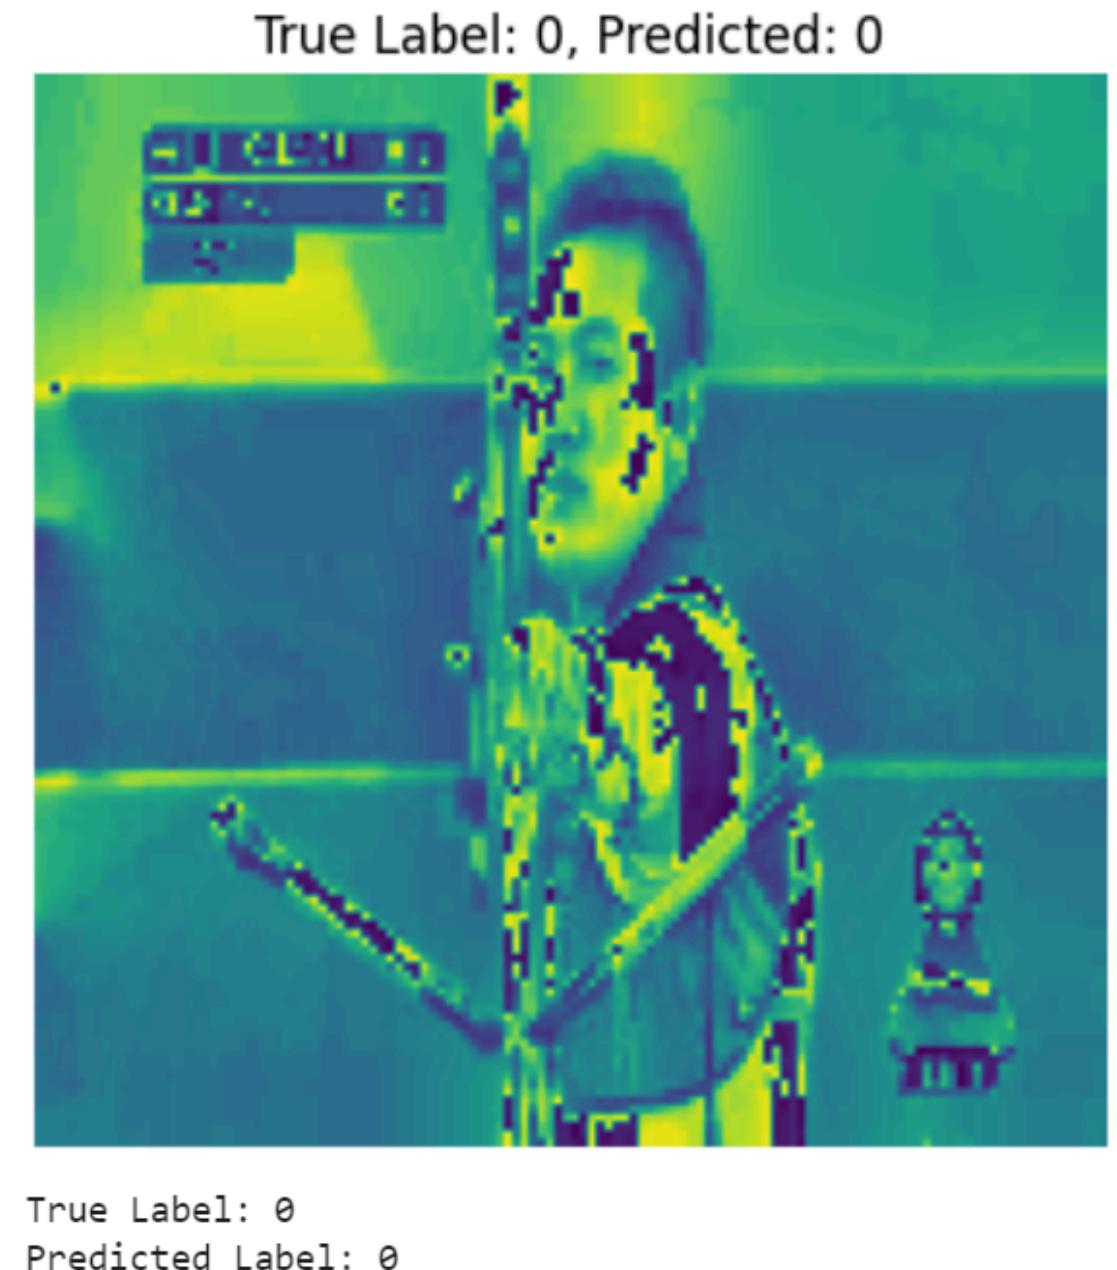
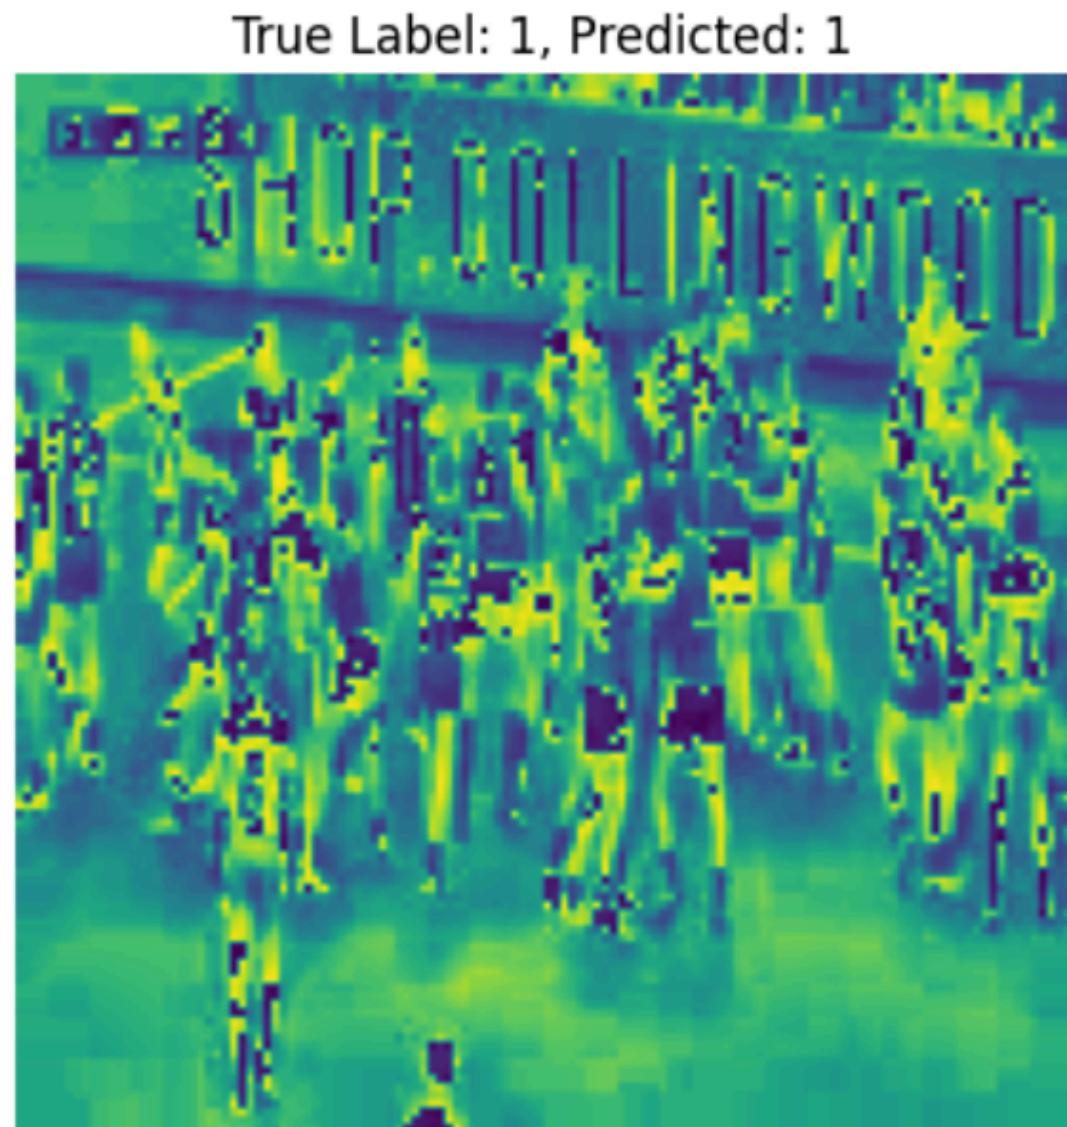
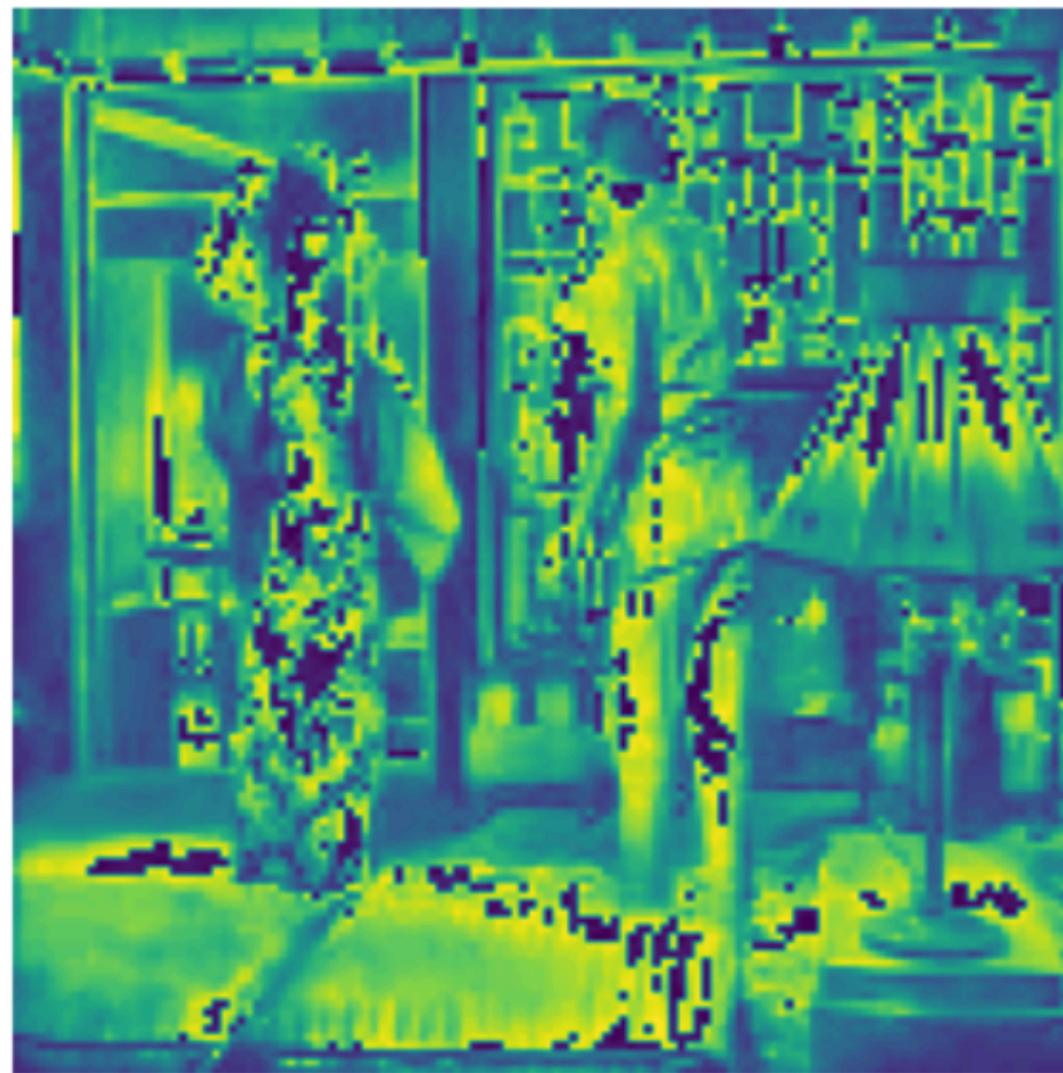
IMAGINES CLAHE

Espacio HLS - Canal L
Clahe
Tamaño 128*128

Accuracy_training:
0.9627

Accuracy_validation: 0.7935





6 / REVISIÓN LITERATURA

6 / REVISIÓN LITERATURA



- Roshankar y Keyvanpour (2023) propusieron redes neuronales convolucionales para predecir crímenes en Chicago, capturando eficazmente dependencias espaciales y patrones delictivos. Entrenadas con datos históricos de 2017 a 2022, superaron a modelos tradicionales como Random Forest.
- Gu et al (2024) combinaron teoría de grafos y redes neuronales convolucionales para predecir crímenes en las calles de Beijing. Utilizaron un modelo de representación gráfica para estructurar las relaciones entre calles y una red neuronal convolucional para conectar la red de calles con las instalaciones urbanas. Este enfoque superó a modelos como SVM, Random Forest, regresión logística y árboles de decisión.
- Singha et al. (2024) desarrollaron modelos predictivos de mortalidad en conflictos armados en Bangladesh utilizando redes neuronales convolucionales y algoritmos tradicionales de machine learning. Entrenaron los modelos con datos de 2010 a 2021, y las redes de grafos tuvieron el mejor rendimiento. También compararon métodos de clustering, encontrando que los basados en grafos identificaron agrupaciones más precisas. Su estudio destaca que los modelos potenciados por grafos comprenden mejor los patrones de conflicto y mortalidad.

MUCHAS GRACIAS

```
    render() {
      return (
        <React.Fragment>
          <div className="py-5">
            <div className="container">
              <Title name="our" title="product">
              <div className="row">
                <ProductConsumer>
                  {(value) => {
                    |   |   |   console.log(value)
                    |   |   |
                  }}
                </ProductConsumer>
              </div>
            </div>
          </div>
        </React.Fragment>
```

BIBLIOGRAFIA

[Gu et al., 2024] Gu, H., Sui, J., y Chen, P. (2024). Graph representation learning for street-level crime prediction.

[Prieto Borges, 2024] Prieto Borges, K. (2024). Violence vs. Non-Violence: 11K Images Dataset. Kaggle. Disponible en: <https://www.kaggle.com/code/kevinprieto20/deteccion-violencia/notebook#Prediccion-y-salva-del-mejor-modelo-tanto-en-.h5-como-en-.json-con-sus-pesos-en-.h5>

[Roshankar y Keyvanpour, 2023] Roshankar, R. y Keyvanpour, M. R. (2023). Spatio-temporal graph neural networks for accurate crime prediction

[Singha et al., 2024] Singha, S. P., Hossain, M. M., Rahman, M. A., y Sharmin, N. (2024). Investigation of graph-based clustering approaches along with graph neural networks for modeling armed conflict bangladesh